Universidade da Beira Interior
Departamento de Informática

Lab 02 — Web Crawling e Web Scraping

Monitor Automático de Notícias de Conflitos Geopolíticos

Unidade Curricular: Extração e Transformação de Dados

Curso: Inteligência Artificial e Ciência de Dados

Autor: Simão Nambi

Número: 53558

Data: 9 de março de 2026

Conteúdo

1 Contextualização **2**

2 Arquitetura do Sistema **2**

3 Tecnologias e Bibliotecas Utilizadas **2**

4 Atributos Recolhidos **2**

5 Filtro Geopolítico **4**

6 Base de Dados SQLite **4**

7 Execução e Resultados **4**
7.1 Primeira Execução — 17:06 5
7.2 Segunda Execução — 17:14 (após correção) 5

8 Boas Práticas e Ética **6**

9 Dificuldades e Soluções **6**

10 Conclusão **7**

1 Contextualização

Este trabalho foi desenvolvido no âmbito da unidade curricular de Extração e Transformação de Dados e consiste na implementação de um sistema automático de *web crawling* e *web scraping* aplicado ao jornal online **Público** (`https://www.publico.pt`).

O objetivo principal é monitorizar notícias relacionadas com conflitos geopolíticos entre países que possam indicar uma escalada para um conflito global, nomeadamente situações associadas a uma possível Terceira Guerra Mundial. O sistema recolhe, filtra e armazena automaticamente artigos relevantes, atribuindo a cada um um *score* de relevância baseado em palavras-chave ponderadas por categoria de gravidade.

O Público foi escolhido por ser um dos principais jornais de referência em Portugal, com cobertura consistente de temas internacionais e de política mundial, e por disponibilizar os seus artigos em formato HTML acessível sem autenticação obrigatória.

2 Arquitetura do Sistema

O projeto foi estruturado em módulos independentes com responsabilidades bem definidas, seguindo o princípio da separação de responsabilidades. A figura seguinte ilustra o fluxo de execução entre módulos:

`main.py`
↓
`crawler_publico.py` → fila de URLs
↓
`scraper.py` → lista de artigos
↓
`filtro_geopolitico.py` → artigos relevantes
↓
`storage.py` + `database.py` → CSV / JSON / SQLite

3 Tecnologias e Bibliotecas Utilizadas

O projeto foi desenvolvido em **Python 3.11** num ambiente virtual (`.venv`). A tabela seguinte detalha as bibliotecas utilizadas:

As bibliotecas `sqlite3`, `logging`, `csv`, `json` e `urllib` fazem parte da biblioteca padrão do Python e não requerem instalação adicional. Apenas `requests`, `beautifulsoup4` e `lxml` necessitam de ser instaladas via:

```
pip install -r requirements.txt
```

4 Atributos Recolhidos

Para cada artigo identificado como relevante, o sistema extrai e armazena os seguintes campos:

Ficheiro	Responsabilidade
`crawler_publico.py`	Verifica `robots.txt`, descobre links de artigos reais filtrando pelo padrão de URL `/YYYY/MM/DD/...` e gere a fila de URLs
`scraper.py`	Acede a cada artigo e extrai título, subtítulo, autor, data, categoria e resumo via parsing HTML com múltiplos fallbacks
`filtro_geopolitico.py`	Analisa título, subtítulo, resumo e URL de cada artigo, calcula score de relevância geopolítica e descarta artigos abaixo do limiar
`storage.py`	Persiste dados em CSV e JSON em modo append, evitando duplicados entre execuções
`database.py`	Gere base de dados SQLite com três tabelas relacionais e regista cada execução do crawler
`logger_config.py`	Configura logging simultâneo para terminal (INFO) e ficheiro (DEBUG) com timestamp e módulo
`main.py`	Orquestra todos os módulos sequencialmente com verificações em cada fase

Tabela 1: Módulos do projeto e respetivas responsabilidades

Biblioteca	Versão	Utilização
`requests`	2.31.0	Requisições HTTP para aceder ao Público
`beautifulsoup4`	4.12.3	Parsing do HTML dos artigos
`lxml`	5.1.0	Parser HTML rápido utilizado pelo BeautifulSoup
`sqlite3`	nativa	Base de dados local (Python built-in, sem instalação)
`logging`	nativa	Registo de eventos, erros e timestamps
`csv / json`	nativa	Exportação de dados estruturados
`urllib`	nativa	Parsing de URLs e verificação do robots.txt

Tabela 2: Bibliotecas utilizadas no projeto

Campo	Tipo	Descrição
`titulo`	texto	Título principal do artigo
`subtitulo`	texto	Lead ou subtítulo (via `og:description`)
`autor`	texto	Nome do jornalista
`data_publicacao`	ISO 8601	Data e hora de publicação
`categoria`	texto	Secção do Público (mundo, politica, economia)
`resumo`	texto	Primeiros parágrafos úteis do artigo
`link`	URL	Endereço completo do artigo
`keywords_encontradas`	texto	Keywords de conflito detetadas, separadas por vírgula
`score_relevancia`	inteiro	Pontuação de relevância normalizada (0–100)
`data_recolha`	ISO 8601	Timestamp do momento de recolha

Tabela 3: Campos extraídos por artigo

5 Filtro Geopolítico

O módulo `filtro_geopolitico.py` é o núcleo inteligente do sistema. Analisa o título (com peso triplo por ser o campo mais fiável), subtítulo, resumo e o próprio URL de cada artigo. O URL é incluído na análise porque contém palavras do tema do artigo em formato legível (por exemplo, `japao-instala-missil-longo-alcance`).

A pontuação é calculada com base em três categorias de palavras-chave e uma lista de regiões em conflito ativo:

Categoria	Peso	Exemplos
Crítico	3	guerra nuclear, terceira guerra, ogiva nuclear, WWIII, bomba nuclear
Alto	2	NATO, invasão, míssil, bombardeamento, fósforo branco, hackers russos, ofensiva militar
Médio	1	tensão, sanções, ciberataque, longo alcance, escalada, petróleo, confronto
Regiões	1	Ucrânia, Taiwan, Gaza, Irão, Japão, Coreia do Norte, Putin, Trump

Tabela 4: Categorias de keywords e respetivos pesos

O score bruto é normalizado para uma escala de 0 a 100 e o limiar mínimo de aceitação foi definido em 2, permitindo capturar artigos mesmo quando o resumo extraído é curto ou o conteúdo relevante está concentrado no título.

6 Base de Dados SQLite

O sistema utiliza **SQLite** para persistência dos dados, não requerendo qualquer instalação adicional por ser uma biblioteca nativa do Python (`import sqlite3`). A base de dados é criada automaticamente em `output/noticias_conflitos.db` na primeira execução.

A base de dados contém três tabelas relacionais:

- `artigos` — dados principais de cada notícia, com constraint `UNIQUE` no campo `link` para evitar duplicados entre execuções consecutivas
- `keywords` — relação 1:N entre artigos e keywords detetadas, com índice para consultas rápidas por palavra-chave
- `execucoes` — registo automático de cada execução do crawler com totais de URLs descobertos, artigos extraídos e artigos relevantes

O sistema suporta três tipos de consulta: por score mínimo, por keyword específica e por data de recolha.

7 Execução e Resultados

Foram realizadas duas execuções no dia 9 de março de 2026. A primeira revelou um problema no filtro de URLs e a segunda, após correção, produziu resultados válidos.

7.1 Primeira Execução — 17:06

Na primeira execução, o crawler recolheu 50 URLs mas incluiu páginas institucionais do Público (perfis de utilizador, assinaturas, ajuda) por falta de filtragem adequada. Como resultado, o filtro geopolítico descartou todos os 48 artigos extraídos (score = 0 na maioria dos casos).

Métrica	**Valor**
URLs na fila	50
Artigos extraídos	48
Erros HTTP 404	2
Artigos relevantes	0
Taxa de relevância	0%

Tabela 5: Resultados da primeira execução (17:06)

7.2 Segunda Execução — 17:14 (após correção)

Após corrigir o filtro de URLs para aceitar apenas caminhos com o padrão `/YYYY/MM/DD/secção/tipo/t` e corrigir a extração da categoria e do título no `scraper.py`, a segunda execução produziu resultados válidos:

Métrica	**Valor**
Seeds processadas	3
URLs na fila	30
Artigos extraídos	30
Erros HTTP	0
Artigos relevantes	10
Taxa de relevância	33,3%
Score médio	5,3 / 100
Score máximo	9 / 100
Score mínimo	2 / 100

Tabela 6: Resultados da segunda execução (17:14)

As keywords mais frequentes nos artigos relevantes foram *guerra* (4x), *petróleo* (3x) e *irão* (2x), refletindo a cobertura jornalística do dia sobre o conflito no Médio Oriente e as suas consequências económicas.

Os artigos mais relevantes identificados foram:

- *Trump mandou Pedro Sánchez sentar-se — vídeo posterior a ataque do Irão é falso* (score 9)
- *Guerra no Médio Oriente: preço do petróleo dispara 25% com novo Ayatollah* (score 9)
- *Japão instala míssil de longo alcance desenvolvido no país* (score 8)
- *HRW acusa Israel de voltar a usar fósforo branco em alvos civis no Líbano* (score 6)

- *Portugal — defesa antimíssil de médio e longo alcance* (score 5)

8 Boas Práticas e Ética

O sistema foi desenvolvido respeitando as seguintes boas práticas:

- **robots.txt** — verificação automática antes de aceder a qualquer URL através da classe `RobotFileParser`
- **Rate limiting** — pausa de 1,5 segundos entre cada pedido HTTP para não sobrecarregar o servidor
- **User-Agent** — identificação clara do crawler nos cabeçalhos HTTP (`Lab02Crawler/1.0; UBI-ETD`)
- **Dados públicos** — recolha exclusiva de artigos de acesso livre, sem contornar paywalls ou autenticação
- **Tratamento de erros** — uso de `try/except` em todas as operações de rede, com registo de erros HTTP, timeouts e falhas de ligação
- **Logging detalhado** — registo de todos os eventos com timestamp, nome do módulo e mensagem descritiva
- **Sem duplicados** — controlo por constraint `UNIQUE` na base de dados e verificação prévia no CSV
- **RGPD** — recolha exclusiva de dados públicos, sem recolha de informação pessoal privada

9 Dificuldades e Soluções

Dificuldade	**Solução**
Crawler a recolher páginas institucionais em vez de artigos	Filtro de URL reforçado: aceita apenas caminhos com ano de 4 dígitos no início (`partes[0].isdigit()`)
Filtro a descartar todos os artigos na primeira execução	Inclusão do URL na análise de texto e redução do score mínimo para 2
Títulos extraídos como "PÚBLICO" em vez do título real	Função `extrair_titulo()` com 3 níveis de fallback, incluindo meta tag `og:title`
Categoria extraída como "2026" em vez de "mundo"	Correção do índice no parsing do URL: `path_parts[3]` em vez de `path_parts[0]`
Erros HTTP 404 em URLs de utilizador	Tratados com `try/except` e registados no log sem interromper a execução
Duplicados em execuções consecutivas	Constraint `UNIQUE` na base de dados e verificação prévia dos links no CSV

Tabela 7: Principais dificuldades encontradas e soluções adotadas

10 Conclusão

O sistema desenvolvido implementa um pipeline completo e funcional de recolha, filtragem e armazenamento de notícias geopolíticas a partir do jornal Público. O projeto passou por duas iterações de desenvolvimento, com a segunda execução a produzir 10 artigos relevantes de 30 analisados, correspondendo a uma taxa de relevância de 33,3%.

A principal dificuldade encontrada foi o refinamento do filtro de URLs para garantir que apenas artigos reais fossem processados, problema resolvido com a análise do padrão estrutural dos endereços do Público. A extração do título também exigiu múltiplos fallbacks para contornar a estrutura HTML variável entre tipos de artigo.

O filtro geopolítico baseado em keywords ponderadas demonstrou ser eficaz para identificar notícias relevantes, especialmente após a inclusão do URL como campo adicional de análise.

Como trabalho futuro seria interessante adicionar suporte a notificações automáticas via *webhook* para Discord ou Telegram quando artigos com score elevado fossem detetados, bem como um módulo de visualização de tendências ao longo do tempo com recurso a gráficos gerados com `matplotlib`.